

Familienname, Vorname (bitte durch eine Leerspalte trennen)

[illegible]

IHK

Bereich		Berufsnummer				IHK-Nummer		Prüfungsnummer			
7	3	1	2	0	3						
Sp. 1-2		Sp. 3-6				Sp. 7-9		Sp. 10-14			

Termin: Mittwoch, 29. November 2023

Abschlussprüfung Winter 2023/24

1203

2 Sicherstellen der Datenqualität

Fachinformatiker
Fachinformatikerin
Daten- und Prozessanalyse

Teil 2 der Abschlussprüfung

4 Aufgaben

90 Minuten Prüfungszeit

100 Punkte

Bearbeitungshinweise

1. Bevor Sie mit der Bearbeitung der Aufgaben beginnen, überprüfen Sie bitte die **Vollständigkeit** dieses Aufgabensatzes. Die Anzahl der zu bearbeitenden Aufgaben ist auf dem Deckblatt links angegeben. Wenden Sie sich bei Unstimmigkeiten sofort an die Aufsicht, weil Reklamationen am Ende der Prüfung nicht anerkannt werden können.
2. Füllen Sie zuerst die **Kopfzeile** aus. Tragen Sie Ihren Familiennamen, Ihren Vornamen und Ihre Prüflings-Nr. in die oben stehenden Felder ein.
3. Lesen Sie bitte den **Text** der Aufgaben ganz durch, bevor Sie mit der Bearbeitung beginnen.
4. Halten Sie sich bei der Bearbeitung der Aufgaben genau an die **Vorgaben der Aufgabenstellung** zum Umfang der Lösung. Wenn z. B. vier Angaben gefordert werden und Sie sechs Angaben anführen, werden nur die ersten vier Angaben bewertet.
5. Tragen Sie die frei zu formulierenden **Antworten dieser offenen Aufgaben** in die dafür lt. Aufgabenstellung vorgesehenen Bereiche (Lösungszeilen, Formulare, Tabellen u. a.) des Arbeitsbogens ein.
6. Sofern nicht ausdrücklich ein Brief oder eine Formulierung in ganzen Sätzen gefordert werden, ist eine **stichwortartige Beantwortung** zulässig.
7. Schreiben Sie deutlich und gut lesbar. Ein nicht eindeutig zuzuordnendes oder **unleserliches Ergebnis** wird als **falsch** gewertet.
8. Zur Lösung der Rechenaufgaben darf ein nicht programmierter, netzunabhängiger **Taschenrechner** ohne Kommunikationsmöglichkeit mit Dritten verwendet werden.
9. Wenn Sie ein **gerundetes Ergebnis** eintragen und damit weiterrechnen müssen, rechnen Sie (auch im Taschenrechner) nur mit diesem gerundeten Ergebnis weiter.
10. Für **Hilfsaufzeichnungen** können Sie das in der Tasche beigelegte Konzeptpapier verwenden. Bewertet werden jedoch grundsätzlich nur Ihre Eintragungen in diesem Aufgabensatz.

Wird vom Korrektor ausgefüllt!

Bewertung

Für die Bewertung gilt die Vorgabe der Punkte in den Lösungshinweisen.

1. Aufg.

--	--

 Punkte 2. Aufg.

--	--

 Punkte 3. Aufg.

--	--

 Punkte 4. Aufg.

--	--

 Punkte

15 16 17 18 19 20 21 22

Prüfungszeit

23

Die entsprechende Ziffer (1, 2 oder 3) finden Sie in der Abfrage nach der Prüfungszeit im Anschluss an die letzte Aufgabe.

Gesamtpunktzahl

24	25	26

Prüfungsort, Datum

Unterschrift

Gemeinsame Prüfungsaufgaben der Industrie- und Handelskammern. Dieser Aufgabensatz wurde von einem überregionalen Ausschuss, der entsprechend § 40 Berufsbildungsgesetz zusammengesetzt ist, beschlossen. Hinweis: Im Interesse einer besseren Lesbarkeit wird in der Aufgabenstellung und in den Angaben zur Aufgabenstellung nur die männliche Form (generisches Maskulinum) verwendet. Die verkürzte Sprachform beinhaltet keine Wertung und die gewählten männlichen Formulierungen gelten uneingeschränkt auch für die weiteren Geschlechter. Die Vervielfältigung, Verbreitung und öffentliche Wiedergabe der Prüfungsaufgaben und Lösungen ist nicht gestattet. Zuwiderhandlungen werden zivil- und strafrechtlich (§§ 27 ff., 106 ff. UrhG) verfolgt. © ZBA Nord-West 2023 – Alle Rechte vorbehalten!

Die Aufgaben 1 bis 4 beziehen sich auf die folgende Ausgangssituation:

Mithilfe der Produkte der AMAG Soft GmbH können über lokale Messstellen im Weinberg Umgebungsdaten, wie zum Beispiel Niederschläge, Temperatur, Feuchtigkeit und Sonneneinstrahlung, ermittelt werden. Die optische Erfassung des Weinbergs erfolgt mittels autonomer Drohnen. Auf Basis der optischen Informationen kann ein KI-System erforderliche Handlungsbedarfe identifizieren und Handlungsempfehlungen geben.

1. Aufgabe (27 Punkte)

Von einigen Reben ist bekannt, ob sie an einem bestimmten Pilz erkrankt sind (K) oder nicht (G). Zudem können mithilfe der optischen Informationen aus Drohnenüberflügen die Messwerte x und y bestimmt werden, die gute Indikatoren für die Erkrankung eines Rebstockes sind.

	Trainingsdaten															Testdaten				
Wert x	4	4	5	5	5	5,5	6	6	10	10	10,5	11	11	11,5	12	5,5	11	10	8	5
Wert y	14	15	14	15	16	14,5	15	16	11	12	10	12	11	10,5	12	15,5	13	14	15	17
Klasse	G	G	G	G	G	G	G	G	K	K	K	K	K	K	K	G	K	K	G	K

K: krank, G: gesund


a) Übertragen Sie zunächst die **Trainingsdaten** (nicht die Testdaten) aus der Tabelle in das Koordinatensystem.

Hinweis: Verwenden Sie zum Einzeichnen der Datenpunkte für die Klasse gesund (G) einen ausgefüllten Kreis • und für die Klasse krank (K) ein Kreuz x.

Zeichnen Sie dann die zwei folgenden möglichen Trenngeraden in das Koordinatensystem ein.

7 Punkte

	Funktionsvorschrift
Gerade 1:	$y = 13,5$
Gerade 2:	$y = 2x - 3$



- b) Die beiden markierten Parameter einer Geradengleichung haben eine bestimmte mathematische Bedeutung.

Benennen Sie die Bedeutung der zwei Parameter.

2 Punkte

$$y = 2 \cdot x - 3$$

$\uparrow$? $\uparrow$?

- c) Beschreiben Sie, woran man mithilfe von Trenngeraden durch Hinschauen erkennt, ob ein Rebstock gesund oder krank ist.

2 Punkte

- d) Entscheiden Sie, welche der Geraden die beiden Klassen besser trennt und formulieren Sie eine Arbeitsanweisung, mit der sich eine möglichst gute Trenngerade finden lässt.

4 Punkte

- e) Zeichnen Sie jetzt die Testdatenpunkte in das Koordinatensystem von Aufgabe a) ein. Zeichnen Sie dabei Kästchen um die Punkte der Testdaten, um sie von den Trainingsdaten zu unterscheiden: gesund (G) ☐ und krank (K) ☒.

Ermitteln Sie die Anzahl der richtigen und falschen Vorhersagen für die beiden Geraden.

2 Punkte

Gerade	richtig	falsch
1		
2		

Fortsetzung 1. Aufgabe

Korrekturrand

- f) Die Einteilung in gesunde und kranke Reben anhand von Messdaten und der Trenngeraden kann in zwei Schritten auch mathematisch ermittelt werden.
- (1) Es muss zu einem gegebenem Wert A des Messdatenpunktes der Funktionswert B nach der Funktionsvorschrift der Trenngeraden ermittelt werden.
- (2) Die Differenz zwischen dem Wert B des Messdatenpunktes und dem ermittelten Funktionswert wird berechnet.
- fa) Führen Sie die beiden Berechnungsschritte für die zwei folgenden Messdatenpunkte aus.

Hinweis: Verwenden Sie die Funktion der Trenngerade, die mehr richtige Vorhersagen geliefert hat.

4 Punkte

	Messdatenpunkt (A = 3 B = 12)	Messdatenpunkt (A = 9 B = 11)
1		
2		

- fb) Entscheiden Sie anhand der berechneten Differenzen, welcher Klasse die Messdatenpunkte zuzuordnen sind, und begründen Sie die Entscheidung.

3 Punkte

- g) Bringen Sie die folgenden Arbeitsschritte für einen Machine Learning Prozess in eine sinnvolle Reihenfolge. Der erste Schritt ist bereits eingetragen.

3 Punkte

1. Modell evaluieren
2. Daten aufbereiten
3. Bewertungskriterium für die Güte des Modells bestimmen
4. Daten sammeln
5. Modell trainieren (optimale Gerade finden)
6. Daten in Lerndaten und Testdaten unterteilen
7. Modell auswählen (z. B. Trenngerade)

1. Schritt	2. Schritt	3. Schritt	4. Schritt	5. Schritt	6. Schritt	7. Schritt
4						

2. Aufgabe (25 Punkte)

Die Drohnen liefern sehr zuverlässig die Daten der Weinreben. Jetzt gilt es, die Daten auszuwerten. Dazu liegen verschiedene Dateien der Flüge vor.

Auszug aus der wein/22092214.csv

	date	time	location	type	status	action
0	22.09.2022	14:35:00	22;81	Allegro	wildwuchs	manuell
1	22.09.2022	14:35:20	22;82	Allegro	gut	keine
2	22.09.2022	14:35:40	23;1	Piroso	trocken	wird behandelt
3	22.09.2022	14:36:00	23;2	Piroso	Schädlinge	wird behandelt
4	22.09.2022	14:36:20	23;3	Piroso	gut	keine

Auszug aus wetter/2209.json

	date	rain	sun	cloudy
0	22.09.2022	0	0.3	0.7

Auszug aus den beiden zusammengeführten Dateien


	date	time	location	type	status	action	rain	sun	cloudy
0	22.09.2022	14:35:00	22;81	Allegro	wildwuchs	manuell	0	0.3	0.7
1	22.09.2022	14:35:20	22;82	Allegro	gut	keine	0	0.3	0.7
2	22.09.2022	14:35:40	23;1	Piroso	trocken	wird behandelt	0	0.3	0.7
3	22.09.2022	14:36:00	23;2	Piroso	Schädlinge	wird behandelt	0	0.3	0.7
4	22.09.2022	14:36:20	23;3	Piroso	gut	keine	0	0.3	0.7

a) Zur Aufbereitung der Daten soll der Datamining Process CRISP verwendet werden.

Beschriften Sie die Grafik mit den angegebenen sechs Schritten, indem Sie die korrekten Ziffern eintragen.

6 Punkte

(1) Evaluation, (2) Data Preparation, (3) Business Understanding, (4) Deployment, (5) Modeling, (6) Data Understanding



Fortsetzung 2. Aufgabe

Korrekturrand

- b) Folgendes Python Skript soll die Daten von den Dateien **wein/22092214.csv** und **wetter/2209.json** einlesen und passend zusammenführen.

Korrigieren Sie zwei Fehler.

4 Punkte

```
1 # importieren der Panda Bibliothek
2 import pandas as pd

3 # eingelesene csv_df und wetter_df verknüpfen und in data speichern
4 data = pd.merge(csv_df, wetter_df, on = "date", how = "inner")

5 # dronen csv einlesen und in der Variable csv_df speichern
6 csv_df = pd.read_csv("wein/22092214.csv")

7 # wetter json einlesen und in der Variable wetter_df speichern
8 wetter_df = pd.read_json("wetter/2209.xlsx")
```

- c) Der Merge Befehl der Python Pandabibliothek entspricht einem JOIN von SQL.

Erklären Sie das Konzept hinter einem JOIN.

3 Punkte

d) Zum Verarbeiten von Daten haben Sie einen englischen Text gefunden:

Korrekturrand

Selecting the data using simple conditions

This is similar to selecting data from a table in SQL with the 'where' clause. Similarly, in Pandas we can select data from the Pandas DataFrame with a condition. For example, from a resident data frame saved in the variable **residents**. We want to get all the records for the state of Andorra (i.e. state is Andorra). The following is an example of selecting data with a condition:

```
residents[residents.state == 'Andorra']
```

Selection of data with multiple conditions

Sometimes it is not enough to select data by simple conditions to meet our requirements. In real-world problems, we must select data by applying multiple conditions. Often we need to select data by applying two or more conditions simultaneously. For example, suppose we need to select all records of residents where:

Condition 1: State is Andorra.

Condition 2: Salary is less than or equal to 5000.

So, in case of AND condition, we can select only those records that qualify for both the conditions. The following is an example to demonstrate this case:

```
residents[(residents.state == 'Andorra') & (residents.salary <= 5000)]
```

Suppose we need to retrieve such records from residents, where:

Condition 1: The salary is less than 2000.

Condition 2: State is Andorra.

So, in this case, we can select records that satisfy either condition 1 or condition 2. Such arrangement of condition is OR, that is, if one of the conditions is true or satisfied, that record will be selected. The following example is intended to illustrate case 2 (OR)

```
residents[(residents.state == 'Andorra') | (residents.salary < 2000)]
```

da) Schreiben Sie anhand der Beispiele einen Befehl, der alle Weinsorten (type) Piroso aus dem DataFrame data auflistet.

4 Punkte

db) Schreiben Sie einen Befehl, der alle Weinreben auflistet, welche gesund sind und keine Aktion benötigt.

4 Punkte


dc) Schreiben Sie den Befehl, welcher alle Weinreben auflistet, die manuell behandelt werden müssen oder von Schädlingen befallen sind.

4 Punkte

3. Aufgabe (28 Punkte)

Korrekturrand

Die Datenbasis für die Auswertungen der Weine liegt in einer relationalen Datenbank. Ein Ausschnitt dieser Datenbank ist als relationales Datenbankmodell abgebildet:



Die Weineigenschaften sind z. B. Restzuckergehalt, pH-Wert, Schwefeldioxid-Gehalt und eine Qualitätseinstufung zwischen 0 und 10.

Sie sollen die folgenden Fragen durch SQL-Statements beantworten.

- a) Es soll eine Liste aller Weine, welche einen Restzuckerwert unter 2 haben, erstellt werden.

Sortieren Sie so, dass die Weine mit niedrigstem Zucker und höchstem Qualitätswert oben in der Liste stehen. Alle Werte sollen angezeigt werden.

6 Punkte

Hinweis: Die Qualität des Weins steht in der Tabelle Wein und nicht in Eigenschaft.

- b) Ermitteln Sie den höchsten, niedrigsten und den durchschnittlichen Qualitätswert jeder Weinregion in der Datenbank. 7 Punkte

SQL-Syntax (Auszug)

Syntax	Beschreibung
<i>Tabelle</i>	
CREATE TABLE Tabellename(Spaltenname < DATENTYP >, Primärschlüssel, Fremdschlüssel)	Erzeugt eine neue leere Tabelle mit der beschriebenen Struktur
ALTER TABLE Tabellename ADD COLUMN Spaltenname Datentyp DROP COLUMN Spaltenname Datentyp ADD FOREIGN KEY (Spaltenname) REFERENCES Tabellename(Primärschlüsselspaltenname)	Änderungen an einer Tabelle: Hinzufügen einer Spalte Entfernen einer Spalte Definiert eine Spalte als Fremdschlüssel
CHARACTER	Textdatentyp
DECIMAL	Numerischer Datentyp (Festkommazahl)
DOUBLE	Numerischer Datentyp (Doppelte Präzision)
INTEGER	Numerischer Datentyp (Ganzzahl)
DATE	Datum (Format DD.MM.YYYY)
PRIMARY KEY (Spaltenname)	Erstellung eines Primärschlüssels
FOREIGN KEY (Spaltenname) REFERENCES Tabellename(Primärschlüsselspaltenname)	Erstellung einer Fremdschlüssel-Beziehung
DROP TABLE Tabellename	Löscht eine Tabelle
<i>Befehle, Klauseln, Attribute</i>	
SELECT * Spaltenname1 [, Spaltenname2, ...]	Wählt die Spalten einer oder mehrerer Tabellen, deren Inhalte in die Liste aufgenommen werden sollen; alle Spalten (*) oder die namentlich aufgeführten
FROM	Name der Tabelle oder Namen der Tabellen, aus denen die Daten der Ausgabe stammen sollen
SELECT ... FROM ... (SELECT ... FROM ... WHERE ...) AS tbl WHERE ...	Unterabfrage (subquery), die in eine äußere Abfrage eingebettet ist. Das Ergebnis der Unterabfrage wird wie eine Tabelle – hier mit Namen "tbl" – behandelt.
SELECT DISTINCT	Eliminiert Redundanzen, die in einer Tabellen auftreten können, Werte werden jeweils nur einmal angezeigt.
JOIN / INNER JOIN	Liefert nur die Datensätze zweier Tabellen, die gleiche Datenwerte enthalten
LEFT JOIN / LEFT OUTER JOIN	Liefert von der erstgenannten (linken) Tabelle alle Datensätze und von der zweiten Tabelle jene, deren Datenwerte mit denen der ersten Tabelle übereinstimmen
RIGHT JOIN / RIGHT OUTER JOIN	Liefert von der zweiten (rechten) Tabelle alle Datensätze und von der ersten Tabelle jene, deren Datenwerte mit denen der zweiten Tabelle übereinstimmen
WHERE	Bedingung, nach der Datensätze ausgewählt werden sollen
WHERE EXISTS (subquery) WHERE NOT EXISTS (subquery)	Die Bedingungen EXISTS prüft, ob die Suchbedingung einer Unterabfrage mindestens eine Zeile zurückliefert. NOT EXIST negiert die Bedingung.
WHERE ... IN (subquery) WHERE NOT... IN (subquery)	Der Wert des Datenfeldes ist in der ausgewählten Menge vorhanden. Der Wert des Datenfeldes ist in der ausgewählten Menge nicht vorhanden.
GROUP BY Spaltenname1 [,Spaltenname2, ...] HAVING Bedingung	Gruppierung (Aggregation) nach Inhalt des genannten Feldes
ORDER BY Spaltenname1 [,Spaltenname2, ...] ASC DESC	Sortierung nach Inhalt des genannten Feldes oder der genannten Felder ASC: aufsteigend; DESC: absteigend

SQL-Syntax (Auszug)

Syntax	Beschreibung
Datenmanipulation	
DELETE FROM Tabellenname	Löschen von Datensätzen in der genannten Tabelle
UPDATE Tabellenname SET	Aktualisiert Daten in Feldern einer Tabelle
INSERT INTO Tabellenname[(spalte1, spalte2, ...)] VALUES (Wert für Spalte 1 [, Wert für Spalte 2, ...]) oder SELECT ... FROM ... WHERE	Fügt Datensätze in die genannte Tabelle, die entweder mit festen Werten belegt oder Ergebnis eines SELECT-Befehls sind
Berechtigungen kontrollieren	
CREATE Benutzer Rolle IDENTIFIED BY 'Passwort'	Erzeugt einen neuen Benutzer oder eine neue Rolle mit einem Passwort
GRANT Recht Rolle ON *.* Datenbank.* Datenbank.Objekt TO Benutzer Rolle [WITH GRANT OPTION]	Weist einem Benutzer oder einer Rolle ein Recht auf ein bestimmtes Datenbank-Objekt zu Weist einem Benutzer eine Rolle zu
REVOKE Rechte Rollen ON *.* Datenbank.* Datenbank.Objekt FROM Benutzer Rolle	Entzieht einem Benutzer oder einer Rolle ein Recht auf ein bestimmtes Datenbank-Objekt Entzieht einem Benutzer eine Rolle
Aggregatfunktionen	
AVG (Spaltenname)	Ermittelt das arithmetische Mittel aller Werte im angegebenen Feld
COUNT (Spaltenname *)	Ermittelt die Anzahl der Datensätze mit Nicht-NULL-Werten im angegebenen Feld oder alle Datensätze der Tabelle (dann mit Operator *)
SUM (Spaltenname Formel)	Ermittelt die Summe aller Werte im angegebenen Feld oder der Formelergebnisse
MIN (Spaltenname Formel)	Ermittelt den kleinsten aller Werte im angegebenen Feld
MAX (Spaltenname Formel)	Ermittelt den größten aller Werte im angegebenen Feld
Funktionen	
LEFT (Zeichenkette, Anzahlzeichen)	Liefert <i>Anzahlzeichen</i> der Zeichenkette von links.
RIGHT (Zeichenkette, Anzahlzeichen)	Liefert <i>Anzahlzeichen</i> der Zeichenkette von rechts.
CURRENT	Liefert das aktuelle Datum mit der aktuellen Uhrzeit
CONVERT (time,[DatumZeit])	Liefert die Uhrzeit aus einer DatumZeit-Angabe
DATE (Wert)	Wandelt einen Wert in ein Datum um
DAY (Datum)	Liefert den Tag des Monats aus dem angegebenen Datum
MONTH (Datum)	Liefert den Monat aus dem angegebenen Datum
TODAY	Liefert das aktuelle Datum
WEEKDAY (Datum)	Liefert den Tag der Woche aus dem angegebenen Datum
YEAR (Datum)	Liefert das Jahr aus dem angegebenen Datum
DATEADD (Datumsteil, Intervall, Datum)	Fügt einem Datum ein Intervall (ausgedrückt in den unter Datumsteil angegebenen Einheiten) hinzu
DATEDIFF (Datumsteil, Anfangsdatum, Enddatum) Datumsteile: DAY, MONTH, YEAR	Liefert Enddatum-Startdatum (ausgedrückt in den unter Datumsteil angegebenen Einheiten)
Operatoren	
AND	Logisches UND
LIKE	Überprüfung von Text auf Gleichheit wenn Platzhalter ("regular expressions") eingesetzt werden.
NOT	Logische Negation
OR	Logisches ODER
IS NULL	Überprüfung auf NULL
=	Test auf Gleichheit
>, >=, <, <=, <>	Test auf Ungleichheit
*	Multiplikation
/	Division
+	Addition, positives Vorzeichen
-	Subtraktion, negatives Vorzeichen

- c) Erstellen Sie eine Liste der Weingüter, mit der Anzahl der produzierten Weine, welche eine Qualitätsstufe von 7 oder höher erhalten haben. Nur Weingüter mit mehr als zwei Weinen sollen in der Liste aufgeführt werden. Die Weingüter mit den meisten guten Weinen sollen oben in der Liste stehen. 7 Punkte

- d) Erstellen Sie eine Liste aller Weine, welche die höchste in der Datenbank enthaltene Qualitätsstufe erreichen. 5 Punkte

- e) Die eingetragenen Werte des Weinguts „Richards Rebe“ wurden durch einen Cyberangriff manipuliert.
Entfernen Sie diese Weine aus der Datenbank. Es kann von einer Löschweitergabe an die Detailtabellen ausgegangen werden. 3 Punkte



4. Aufgabe (20 Punkte)

Korrekturrand

Alle Messdaten der Weinberge, sowohl die von lokalen Messstationen wie auch die von Drohnen, werden von der AMAG Soft GmbH in der Cloud-Datenbank gespeichert. Das Bildmaterial und die Messdaten werden über KI-Tools, die ebenfalls in der Cloud liegen ausgewertet. So ist es damit z. B. möglich, den optimalen Zeitpunkt zu ermitteln, um die Weinreben zu bearbeiten und auch wie diese Bearbeitung durchgeführt wird. Auf diese Weise könnte der Verbrauch an Pflanzenschutzmitteln drastisch gesenkt werden oder auch der zu produzierende Wein vorgeschlagen werden.

- a) Nennen Sie zwei Nachteile der Cloud-Datenspeicherung und erläutern Sie jeden Nachteil mit einem Satz. 4 Punkte

- b) Stellen Sie den Schutzbedarf für folgende Gefahren im Hinblick auf Cloud-Computing fest: 16 Punkte

Gefahr	Schutzbedarf		Begründung
Datenbank in der Cloud	Verfügbarkeit	sehr hoch	
	Integrität		
	Vertraulichkeit	normal	
KI-Analysetools in der Cloud	Verfügbarkeit		
	Integrität		
	Vertraulichkeit		

PRÜFUNGSZEIT – NICHT BESTANDTEIL DER PRÜFUNG!

Wie beurteilen Sie nach der Bearbeitung der Aufgaben die zur Verfügung stehende Prüfungszeit?

- ☐ 1 Sie hätte kürzer sein können.
 ☐ 2 Sie war angemessen.
 ☐ 3 Sie hätte länger sein müssen.

☐